

Análise técnica dos 36 treinamentos do TCC

Auditoria consolidada de desempenho, tempo, hardware, qualidade e comparabilidade.

Resumo técnico

A suíte canônica terminou: **36 de 36 runs** estão com status `completed`, reunindo **2.486 epochs** e **88,86 horas** de treinamento efetivo. Não é necessário executar comando de retomada. Os avisos exibidos ao fim do FER2013 não invalidaram o run: o epoch 46 foi registrado integralmente, o early stopping ocorreu na janela prevista e checkpoint, avaliação e previsões finais estão presentes.

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

Runs concluídos

36

Conclusão da suíte canônica

Planejados 36

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

Horas

88.86

Custo total de treinamento

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

Epochs

2,486

Volume efetivamente registrado

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

Macro-F1

99.7%

Melhor macro-F1 de teste

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

RAM

58.9%

Maior uso de RAM observado

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

VRAM (GiB)

7.64

Maior alocação de VRAM observada

Source: Resumo consolidado da auditoria

Table: outputs/training-analysis-2026-08-02/analysis_overview.json

Desempenho de teste

O maior macro-F1 foi **99,6749%**, no **GTSRB com oversampling**. A melhor estratégia dependeu do dataset: undersampling venceu CIFAR-10, EMNIST Balanced e KMNIST; oversampling venceu CIFAR-100 Coarse, FER2013 e GTSRB; pesos de classe venceu MNIST; e o baseline sem balanceamento venceu Fashion-MNIST e SVHN. Em vários casos a diferença foi pequena, portanto a escolha deve considerar também custo e estabilidade por classe.


Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Macro-F1 de teste por dataset e balanceamento

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv



Efeito do balanceamento


Na média dos nove datasets, oversampling ficou praticamente neutro contra o baseline (**-0,009 ponto percentual** de macro-F1), enquanto undersampling perdeu **4,00 pontos percentuais** em média. Essa perda é concentrada no FER2013 (**-19,28 p.p.**) e no GTSRB (**-13,69 p.p.**), onde descartar exemplos prejudicou classes difíceis. Pesos de classe foi exatamente equivalente ao baseline nos datasets já balanceados e caiu nos mais desbalanceados, especialmente no FER2013.

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Variação de macro-F1 contra o baseline sem balanceamento

Source: Métricas consolidadas por run
Table: outputs/training-analysis-2026-08-02/run_metrics.csv




Tempo e eficiência

O run mais demorado foi **GTSRB com oversampling**, com **9,90 h**; o mais curto foi FER2013 com undersampling, com **4,21 min**, porque o conjunto efetivo foi drasticamente reduzido. Os 36 runs somaram **88,86 h**. GTSRB e SVHN dominam o custo, enquanto os datasets 28×28 e 64×64 têm epochs muito mais curtos.

Source: Métricas consolidadas por run
Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Tempo de treinamento por dataset e balanceamento

Source: Métricas consolidadas por run
Table: outputs/training-analysis-2026-08-02/run_metrics.csv



Uso de hardware

A telemetria da **NVIDIA GeForce RTX 3050 de 8 GB** registrou pico de **7,64 GiB de VRAM**, RAM do sistema em **58,9%**, RSS do processo em **9,14 GiB** e GPU a no máximo **61 °C**. A utilização média ponderada da GPU foi apenas **25,0%**, sinal de que parte do tempo foi limitada pelo carregamento/preprocessamento de dados ou pela CPU. Não há evidência de OOM ou disco cheio nos runs concluídos. Os 12 runs finais (SVHN, GTSRB e FER2013) estão no disco E:, enquanto os 24 anteriores permanecem no C:; esta análise consolida os dois locais.


Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Throughput e utilização média da GPU por run

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv



Detalhamento completo por run

As três tabelas seguintes cobrem os 36 runs: métricas de teste, epochs e tempo, e telemetria de hardware. Para runs retomados, o tempo canônico é a soma dos registros por epoch, evitando subcontagem no resumo da tentativa final.

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Métricas de teste dos 36 runs

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Dataset	Balanceamento	Accuracy	Balanced acc.	Macro-F1	Δ vs baseline	Melhor epoch	Epochs	Amostras teste
GTSRB	Oversampling	99.5%	99.7%	99.7%	+0.3%	51	61	5,876
GTSRB	Sem balanceamento	99.4%	99.4%	99.4%	0%	62	72	5,876
MNIST	Pesos de classe	99%	99%	99%	+0.1%	48	58	10,498
MNIST	Sem balanceamento	98.9%	98.9%	98.9%	0%	45	55	10,498
MNIST	Undersampling	98.9%	98.9%	98.9%	-0%	63	73	10,498
MNIST	Oversampling	98.9%	98.9%	98.9%	-0%	34	44	10,498
GTSRB	Pesos de classe	98.3%	98.8%	98.6%	-0.8%	80	90	5,876
KMNIST	Undersampling	98.5%	98.5%	98.5%	+0.3%	59	69	10,500
KMNIST	Oversampling	98.4%	98.4%	98.4%	+0.1%	40	50	10,500
KMNIST	Sem balanceamento	98.3%	98.3%	98.3%	0%	33	43	10,500
KMNIST	Pesos de classe	98.3%	98.3%	98.3%	0%	33	43	10,500
Fashion-MNIST	Sem balanceamento	92.1%	92.1%	92.1%	0%	43	53	10,500
Fashion-MNIST	Pesos de classe	92.1%	92.1%	92.1%	0%	43	53	10,500
SVHN	Sem balanceamento	92.4%	91.9%	92%	0%	77	87	14,893
Fashion-MNIST	Undersampling	92%	92%	92%	-0.1%	41	51	10,500

36 results · Showing first 15

Tempo e volume de treinamento dos 36 runs

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Dataset	Balanceamento	Epochs	Melhor	Treino (h)	Média/epoch (s)	Até melhor (h)	Exemplos/s	Exemplos processados	Avaliação (s)
GTSRB	Oversampling	61	51	9.9	584.14	8.33	347.82	12.39M	19.41
SVHN	Pesos de classe	100	97	8.84	336.01	8.57	655.26	20.85M	21.74
SVHN	Sem balanceamento	87	77	7.77	321.56	6.91	648.42	18.14M	19.82
GTSRB	Pesos de classe	90	80	6.38	255.23	5.66	323.11	7.42M	17.38
SVHN	Oversampling	42	32	5.64	483.82	4.33	822.95	16.72M	17.15
GTSRB	Sem balanceamento	72	62	5.2	260.18	4.47	316.96	5.94M	19.31
SVHN	Undersampling	80	70	4.46	200.49	3.9	655.09	10.51M	23.35
EMNIST Balanced	Pesos de classe	95	85	3.29	124.83	2.95	2,213.89	26.25M	22.75
EMNIST Balanced	Undersampling	100	100	3.24	116.61	3.24	2,369.87	27.64M	22.79
EMNIST Balanced	Sem balanceamento	95	85	3.22	121.99	2.89	2,265.51	26.25M	22.32
EMNIST Balanced	Oversampling	91	81	3.02	119.62	2.68	2,310.39	25.15M	21.92
CIFAR-100 Coarse	Undersampling	96	86	2.03	76.12	1.82	1,655.36	12.1M	13.25
CIFAR-10	Oversampling	91	81	1.93	76.39	1.72	1,649.46	11.47M	12.88
CIFAR-100 Coarse	Oversampling	85	75	1.79	75.68	1.58	1,664.98	10.71M	10.98
CIFAR-10	Undersampling	85	75	1.73	73.48	1.52	1,714.76	10.71M	12.27

36 results · Showing first 15

Telemetria de hardware dos 36 runs

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Dataset	Balanceamento	GPU média (%)	GPU p95 (%)	VRAM máx. (GiB)	RAM média (%)	RAM máx. (%)	RSS máx. (GiB)	GPU máx. (°C)	Disco livre mín. (GiB)
GTSRB	Pesos de classe	26.68	97	7.64	54.56	57.1	8.86	59	231.45
GTSRB	Undersampling	34.58	98	7.6	47.32	53.6	8.36	61	231.48
GTSRB	Oversampling	23.01	96.2	7.13	55.62	58.9	9.14	59	231.47
GTSRB	Sem balanceamento	22.48	96	6.93	47.75	51.5	8.05	57	231.5
SVHN	Pesos de classe	16.65	50	5	37.14	41.2	6.43	57	5.76
CIFAR-10	Sem balanceamento	26.21	51	4.92	45.05	48.2	7.49	57	7.1
CIFAR-10	Oversampling	27.13	53	4.87	46.12	48.3	7.5	57	6.92
CIFAR-10	Pesos de classe	27.35	53	4.72	46.57	49	7.6	58	6.83
CIFAR-100 Coarse	Undersampling	28.18	55	4.61	48.91	51.3	7.97	56	6.52
CIFAR-100 Coarse	Oversampling	25.13	50	4.57	49.55	51.7	8.04	55	5.42
CIFAR-10	Undersampling	27.9	56	4.57	45.49	47.9	7.45	59	6.98
CIFAR-100 Coarse	Sem balanceamento	23.75	50	4.41	48.4	51	7.92	54	6.11
EMNIST Balanced	Pesos de classe	32.84	60	4.4	37.25	39.2	6.1	59	7.69
MNIST	Sem balanceamento	32.34	60.2	4.36	20.16	21.7	3.42	58	10.28
FER2013	Pesos de classe	31.64	60	4.34	21.35	21.9	3.41	58	231.4

36 results · Showing first 15

Interpretação dos avisos finais do FER2013

No run `fer2013__zscore__class_weight__seed-42`, o melhor checkpoint ocorreu no epoch **36** e o treinamento encerrou no **46**, exatamente após os **10 epochs** de paciência do early stopping. O log mostra 148/148 batches no epoch 46. A mensagem `input ran out of data` apareceu durante o encerramento do iterador; `use_unbounded_threadpool` foi explicitamente ignorado pelo TensorFlow e os cancelamentos de rendezvous são compatíveis com a desmontagem do pipeline. Como os artefatos de teste foram gravados e o status final é `completed`, não há razão técnica para repetir esse run.


Source: Histórico completo por epoch

Table: outputs/training-analysis-2026-08-02/epoch_metrics_all.csv

Val macro-F1 do FER2013 ao longo dos epochs

Source: Histórico completo por epoch

Table: outputs/training-analysis-2026-08-02/epoch_metrics_all.csv



Comportamento por classe

As métricas macro escondem diferenças importantes. No FER2013, fear permanece entre as classes mais difíceis; no CIFAR-10, cat; e no SVHN, os dígitos 8 e 6. O undersampling do GTSRB derrubou especialmente a classe 0. A tabela resume os extremos; o CSV de apoio contém precisão, recall, F1 e suporte de todas as classes.

Source: Métricas completas por classe

Table: outputs/training-analysis-2026-08-02/per_class_metrics.csv

Classes de maior e menor F1 em cada run

Source: Métricas completas por classe

Table: outputs/training-analysis-2026-08-02/per_class_metrics.csv

Dataset	Balanceamento	Pior classe	F1 pior	Suporte	Melhor classe	F1 melhor	Suporte
FER2013	Undersampling	disgust	16.1%	82	happy	47.4%	1,348
FER2013	Pesos de classe	fear	19.7%	768	happy	64.6%	1,348
CIFAR-100 Coarse	Undersampling	reptiles	28.2%	450	trees	79.2%	450
CIFAR-100 Coarse	Sem balanceamento	non-insect_invertebrates	29.8%	450	trees	77.5%	450
CIFAR-100 Coarse	Pesos de classe	non-insect_invertebrates	29.8%	450	trees	77.5%	450
FER2013	Sem balanceamento	fear	30.9%	768	happy	72.6%	1,348
CIFAR-100 Coarse	Oversampling	reptiles	32%	450	trees	77.3%	450
FER2013	Oversampling	fear	32.8%	768	happy	69.1%	1,348
EMNIST Balanced	Oversampling	21	49.6%	420	32	98.1%	420
EMNIST Balanced	Sem balanceamento	21	51.5%	420	32	98.8%	420
EMNIST Balanced	Pesos de classe	21	51.5%	420	32	98.8%	420
CIFAR-10	Oversampling	cat	52.4%	900	automobile	84.3%	900
EMNIST Balanced	Undersampling	21	53.1%	420	32	99.2%	420
CIFAR-10	Undersampling	cat	53.7%	900	ship	84.5%	900
GTSRB	Undersampling	0	54.5%	31	16	99.3%	67

Escopo, método e qualidade dos dados

Foram incluídos somente os 36 runs canônicos da suíte atual: nove datasets, quatro modos, normalização z-score e seed 42. Tentativas interrompidas antigas e o CINIC-10, que não pertence mais à suíte, foram excluídos. A auditoria executou **396 verificações** de arquivos, status, sequência de epochs, previsões, suporte, checkpoints, tempos e valores finitos. Não houve falha crítica ou alta. A única falha média foi a subcontagem do resumo de tempo do SVHN com pesos de classe; o histórico completo por epoch resolve essa diferença sem afetar o modelo ou suas métricas.

Source: Controles de qualidade e comparabilidade

Table: outputs/training-analysis-2026-08-02/quality_checks.csv

Comparabilidade interna por dataset

Source: Controles de qualidade e comparabilidade

Table: outputs/training-analysis-2026-08-02/quality_checks.csv

Dataset	Splits distintos	Fontes distintas	Batches distintos	Versões TF	Limites shuffle	Comparável
CIFAR-10	1	1	1	1	1	1
CIFAR-100 Coarse	1	1	1	1	1	1
EMNIST Balanced	1	1	1	1	1	1
Fashion-MNIST	1	1	1	1	1	1
FER2013	1	1	1	1	1	1
GTSRB	1	1	1	1	1	1
KMNIST	1	1	1	1	1	1
MNIST	1	1	1	1	1	1
SVHN	1	1	1	1	1	1

Limitações e robustez

Cada configuração foi executada com uma única seed (**42**), então diferenças pequenas devem ser tratadas como descritivas, não como evidência estatística de superioridade. Os seis primeiros datasets não registraram explicitamente o limite de shuffle em MiB; SVHN, GTSRB e FER2013 usaram limite de 1.024 MiB. Isso não quebra as comparações entre os quatro modos do mesmo dataset, mas recomenda cautela ao comparar eficiência absoluta entre datasets de fases distintas.

Source: Métricas consolidadas por run

Table: outputs/training-analysis-2026-08-02/run_metrics.csv

Recomendações

1. Use **sem balanceamento** como baseline padrão e escolha outra estratégia apenas quando o ganho por classe ou macro-F1 justificar o custo.
2. Prefira **oversampling** a undersampling nos datasets fortemente desbalanceados; para FER2013, o ganho global é pequeno, mas merece análise específica da classe fear.
3. Evite undersampling no GTSRB e FER2013.
4. Para conclusões do TCC, repita as configurações candidatas com pelo menos 3–5 seeds e relate média e desvio-padrão/intervalo de confiança.
5. Para reduzir tempo, faça profiling do pipeline `tf.data`: a GPU média de 25% mostra margem para prefetch, paralelismo e cache mais eficientes.

Próximas perguntas

Vale confirmar se os ganhos de CIFAR-100, GTSRB e KMNIST persistem em outras seeds; medir o custo energético por run; e testar se focal loss ou augmentação direcionada melhora as classes raras do FER2013 sem o custo do oversampling integral.