

Análise técnica da varredura de batch size do KMNIST

Auditoria de qualidade, desempenho, tempo e telemetria de 32 runs KMNIST com batch size variável.

Resumo técnico

A varredura foi concluída com **32 de 32 runs** e **1600 épocas** registradas. As métricas finais de teste estão presentes para todos os batches. A maior macro-F1 de teste foi **98.4855%** no batch **16**. As **32 runs** têm cobertura completa de duração por época e entram na comparação de eficiência. Os batches **48, 64, 224** têm telemetria de hardware parcial; suas métricas de modelo e tempo continuam válidas, mas os picos de hardware devem ser lidos como amostras.

Source: Resumo consolidado da varredura KMNIST

Table: analysis_overview.json

Runs concluídas

32

Conclusão e integridade estrutural

Planejadas 32

Source: Resumo consolidado da varredura KMNIST

Table: analysis_overview.json

Macro-F1

98.5%

Maior macro-F1 de teste observada

Batch 16

Source: Resumo consolidado da varredura KMNIST

Table: analysis_overview.json

Batch

432

Menor duração média por época entre as runs comparáveis

s/época 50.73

Source: Resumo consolidado da varredura KMNIST

Table: analysis_overview.json

VRAM (GiB)

5.36

Maior VRAM observada durante treino

Batch 224

Source: Resumo de hardware por batch

Table: hardware_summary.csv

Cobertura completa

32

Runs elegíveis para comparação de eficiência

Com ressalva 0

Source: Controles de qualidade e ressalvas

Table: quality_checks.csv

Qualidade do modelo ao longo dos batches

Os 32 batches usam o mesmo conjunto de teste de 10.500 imagens. A macro-F1 de teste variou de **97.1519%** a **98.4855%**, portanto as diferenças observadas descrevem este único seed e não estabelecem superioridade estatística entre batches próximos.


Source: Métricas e tempo por batch

Table: run_metrics.csv

Macro-F1 de teste por batch size

Source: Métricas e tempo por batch

Table: run_metrics.csv



Eficiência de treino com cobertura completa

Entre as runs comparáveis, o batch **432** teve a menor duração média: **50.73 s por época**. Esse ranking usa apenas histórico completo de epoch_seconds para evitar que uma retomada pareça artificialmente rápida.


Source: Métricas e tempo por batch

Table: run_metrics.csv

Duração média por época nas runs comparáveis

Source: Métricas e tempo por batch


Table: run_metrics.csv



Throughput de treino nas runs comparáveis

Source: Métricas e tempo por batch

Table: run_metrics.csv



Uso de hardware

O maior pico de VRAM observado foi **5.36 GiB** no batch **224**, abaixo dos 8 GiB físicos da RTX 3050. Não houve falha registrada por memória. Os valores de hardware dos batches com telemetria parcial devem ser lidos como amostra, não como pico garantido da run inteira.


Source: Resumo de hardware por batch

Table: hardware_summary.csv

Pico de VRAM observado por batch size

Source: Resumo de hardware por batch

Table: hardware_summary.csv



Convergência de batches selecionados

As cinco curvas abaixo preservam a leitura da convergência sem sobrepor 32 séries. Todas as runs foram treinadas por 50 épocas; a parada antecipada e a redução de taxa foram configuradas para não encurtar o experimento.


Source: Histórico por época

Table: epoch_metrics_all.csv

Macro-F1 de validação por época - batches selecionados

Source: Histórico por época

Table: epoch_metrics_all.csv



Métricas, tempo e hardware por run

As tabelas mostram todas as 32 runs. As colunas de cobertura indicam quais medições podem ser comparadas diretamente.

Source: Métricas e tempo por batch

Table: run_metrics.csv

Métricas de qualidade para cada batch

Source: Métricas e tempo por batch

Table: run_metrics.csv

Batch	Melhor val F1	Teste accuracy	Teste macro-F1	Teste loss
16	98.6%	98.5%	98.5%	0.09
32	98.5%	98.4%	98.4%	0.08
48	98.3%	98.3%	98.3%	0.1
64	98.4%	98.1%	98.1%	0.08
80	98.1%	98.1%	98.1%	0.09
96	98.2%	98%	98%	0.11
112	98%	98%	98%	0.1
128	97.9%	97.9%	97.9%	0.12
144	97.9%	98%	98%	0.11
160	98%	97.8%	97.8%	0.12
176	97.8%	97.8%	97.8%	0.12
192	97.7%	97.6%	97.6%	0.14
208	97.7%	97.8%	97.8%	0.12
224	97.8%	97.7%	97.7%	0.13
240	97.7%	97.7%	97.7%	0.12

Tempo de treinamento por batch

Source: Métricas e tempo por batch

Table: run_metrics.csv

Batch	Treino (s)	s/época	Exemplos/s	Avaliação (s)
16	9,339.07	186.78	262.34	65.78
32	6,692.64	133.85	366.07	44.86
48	4,794.67	95.89	510.98	30.39
64	4,357.78	87.16	562.21	29.19
80	3,908.65	78.17	626.82	27.37
96	3,676.81	73.54	666.34	25.99
112	3,285.09	65.7	745.79	23.42
128	3,278.58	65.57	747.27	23.18
144	3,013.63	60.27	812.97	22.2
160	3,052.36	61.05	802.66	23.87
176	2,940.09	58.8	833.31	21.54
192	2,672.72	53.45	916.67	21.37
208	2,664.06	53.28	919.65	21.16
224	2,913.6	58.27	840.89	30.96
240	3,602.8	72.06	680.03	23.69

Hardware observado em cada batch

Source: Resumo de hardware por batch

Table: hardware_summary.csv

Batch	Cobertura	GPU média (%)	VRAM máx. (GiB)	GPU máx. (C)	RAM máx. (%)
16	98%	33.72	5.01	57	23.1
32	100%	27.6	4.14	49	23.9
48	8%	31.03	2.52	52	20.4
64	82%	28.52	2.92	50	23.7
80	100%	22.73	2.83	49	22.2
96	100%	21.26	2.76	50	23.7
112	100%	18.58	2.79	50	24.1
128	100%	18.5	2.78	50	24
144	100%	18.31	2.77	54	22.3
160	100%	18.85	2.78	48	22.4
176	100%	19.23	2.8	48	22.8
192	100%	19.56	2.79	49	24.6
208	100%	23.66	3.65	52	23.6
224	14%	36.93	5.36	56	20.9
240	100%	36.49	5.19	56	22.9

32 results · Showing first 15

Limitações e verificações de robustez

As métricas de qualidade foram verificadas contra status, 50 épocas sequenciais, previsões e suporte do teste. Os batches 48, 64, 224 não preservaram todos os eventos epoch_end da telemetria; por isso os picos de VRAM e demais máximos desses pontos não representam necessariamente a run inteira. Os seus históricos de tempo por época estão completos. Há somente um seed por batch, então pequenas diferenças de macro-F1 podem refletir a variabilidade de otimização.

Source: Controles de qualidade e ressalvas

Table: quality_checks.csv

Próximos passos recomendados

1. Reexecutar os batches 48, 64, 224 em uma nova pasta de saída se for necessária uma comparação integral de hardware desses pontos.

2. Repetir os batches mais promissores com ao menos três seeds para estimar variância de qualidade.
3. Selecionar o menor batch que atinja a qualidade-alvo e mantenha a eficiência/hardware dentro dos limites operacionais.

Questões em aberto

A varredura mede um único dataset, arquitetura, normalização e seed. A escolha final de batch pode mudar em outros datasets ou com replicações adicionais.