

Benchmark de quantização KMNIST

Análise técnica consolidada: qualidade, convergência, hardware, tempo e implantação

Resultado principal. Os cinco tratamentos foram concluídos. O relatório preserva as ressalvas de validade: INT4-QAT é emulado, FP16 não produziu FlatBuffer LiteRT e a PTQ INT8 é um grafo híbrido com tensores float auxiliares.


Checagens de integridade. Todas as checagens obrigatórias passaram.

Principais achados.

- Melhor acurácia: INT4-QAT (emulado) (98.010%).
- INT8-QAT: -0.133% de diferença de acurácia contra FP32.
- INT8-PTQ: 0.297 MiB e 3610.4 exemplos/s em LiteRT/CPU; validade float_or_hybrid.
- INT4-QAT é um resultado numérico emulado, não um artefato INT4 LiteRT implantável.


Qualidade de teste


Variante	Acurácia	Precisão macro	Recall macro	Macro-F1	AUC macro	MSE logits
FP32	97.857%	97.865%	97.857%	97.855%	99.945%	0.000000
FP16	97.295%	97.307%	97.295%	97.296%	99.918%	5.753087
INT8-QAT	97.724%	97.733%	97.724%	97.725%	99.941%	4.211951
INT4-QAT (emulado)	98.010%	98.015%	98.010%	98.010%	99.956%	8.096385
INT8-PTQ	96.648%	96.677%	96.648%	96.640%	99.868%	1.583283



Treinamento e uso de hardware



Variante	Épocas	Tempo épocas (s)	Média/época (s)	Treino (ex/s)	GPU média (%)	VRAM pico (GiB)	RSS pico (GiB)
FP32	50	2778.9	59.13	830.7	39.0	4.19	3.03
FP16	50	2828.2	56.56	869.6	32.2	4.21	3.53
INT8-QAT	50	1147.7	22.95	2159.4	45.3	4.52	3.09
INT4-QAT (emulado)	50	1169.8	23.40	2118.0	46.1	4.70	3.21





Implantação LiteRT/CPU e limites de validade

Variante	LiteRT (MiB)	Pesos estimados (MiB)	Conversão	Validade	Latência/batch (ms)	Throughput (ex/s)	RSS infer. (MiB)
FP32	0.813	0.767	completed	float_or_hybrid	76.438	3312.0	1617.6
FP16	—	0.387	failed	failed	—	—	—
INT8-QAT	0.298	0.198	completed	float_or_hybrid	49.081	5141.3	1875.8
INT4-QAT (emulado)	—	0.103	not_exported	emulated_int4	—	—	—
INT8-PTQ	0.297	0.197	completed	float_or_hybrid	63.356	3610.4	2055.7



Deltas contra FP32 e interpretação

Variante	Δ acurácia (p.p.)	Δ Macro-F1 (p.p.)	Δ AUC (p.p.)	MSE logits	Acordo FP32
FP32	0.000	0.000	0.000	0.000000	100.000%
FP16	-0.562	-0.560	-0.027	5.753087	97.352%
INT8-QAT	-0.133	-0.130	-0.004	4.211951	97.629%
INT4-QAT (emulado)	0.152	0.154	0.011	8.096385	97.457%
INT8-PTQ	-1.210	-1.215	-0.077	1.583283	97.495%

Limites: cada variante tem uma única execução com seed 42; os resultados são descritivos e não possuem intervalos de confiança. QAT treinada do zero não isola causalmente apenas o efeito da quantização. A inferência LiteRT é CPU; ela não deve ser comparada diretamente ao desempenho de treino na GPU.

Avisos de qualidade:

- A telemetria registrou menos de 50 eventos `epoch\_end` em FP32 (47). Os CSVs de época e os `training\_summary.json` registram as 50 épocas; por isso este é um aviso de instrumentação, não uma evidência de treino incompleto.
- A conversão LiteRT FP16 falhou; não há métrica de inferência LiteRT/CPU nem tamanho LiteRT para FP16.
- INT4-QAT é fake quantização experimental/emulada; o tamanho de 4 bits é estimado e não representa um artefato LiteRT INT4 implantável.
- O LiteRT INT8-PTQ contém tensores float32 auxiliares; ele é classificado como grafo híbrido/float_or_hybrid, não como INT8 integral.

Recomendação: repetir com múltiplas seeds, consertar a rota FP16 LiteRT, tratar PTQ como híbrida até eliminar tensores float e medir INT4 apenas em um backend com suporte nativo.

Artefatos auditáveis: relatório Markdown, notebook executado, `run\_summary.csv`, `metric\_deltas\_vs\_fp32.csv`, `training\_epochs.csv` e `data\_quality.json`.